Rapport conduite de projet

Faculté des sciences économiques et de gestion

Université de Strasbourg

Indice de prix de l'immobilier en Occitanie

HUREL Elia, CORREGER Mattéo

Supervisé par : EL YAAKOUBI Youssef

8 avril 2026

Sommaire

Introduction **3**

1 Méthodologie **4**

1.1 La base de données : de la donnée brute au nettoyage 4

1.2 Modèle Hédonique 5

1.3 Construction de l'indice de prix 6

2 Résultats et discussions **8**

2.1 Analyse et validation du modèle hédonique 8

2.2 Évolution des prix par type de bien (Maisons et Appartements) 9

2.3 Disparités géographiques et poids des métropoles 10

2.4 Analyse des cycles de marché 13

Conclusion **16**

Introduction

L'Occitanie, issue de la fusion des régions Midi-Pyrénées et Languedoc-Roussillon, est aujourd'hui l'une des régions les plus dynamiques de France. Elle est caractérisée par une attractivité croissante, mais c'est aussi l'une des plus contrastées au niveau immobilier. Entre l'attractivité de la métropole de Toulouse avec l'aéronautique, le dynamisme de Montpellier vers la Méditerranée et les zones plus rurales du Gers ou de l'Ariège, les prix ne suivent pas du tout la même trajectoire. Depuis quelques années, le marché est sous pression : après l'euphorie post-COVID où tout le monde cherchait une maison avec jardin, on fait maintenant face à une remontée des taux d'intérêt qui calme les ventes. Toutefois, la rareté des biens dans les centres-villes de Toulouse et Montpellier maintien des niveaux de prix élevés, créant cette hétérogénéité entre les zones urbaines denses et les territoires ruraux.

Dans ce contexte, une simple moyenne des prix observés ne suffit pas à mesurer l'évolution réelle du marché. Un changement de la moyenne peut simplement refléter une modification de la « qualité » des biens vendus plutôt qu'une véritable variation des prix du marché. Par exemple, si l'on vend beaucoup de petits studios en centre-ville un mois, puis de grandes maisons de campagne le mois suivant, la moyenne va chuter brutalement alors que le prix d'un même bien n'a peut-être pas bougé.

Face à ces évolutions, une question centrale se pose : comment mesurer de manière rigoureuse l'évolution réelle des prix immobiliers, en s'affranchissant des biais liés à la composition des transactions ? L'objectif de ce projet est donc de construire des indices de prix immobiliers à "qualité constante" pour les communes de la région, sur la période 2010-2024. Pour ce faire, nous mobilisons les données DVF+ et un modèle hédonique estimé séparément pour les maisons et les appartements, dont nous détaillons la méthodologie dans la partie suivante, puis les résultats ainsi que les limites.

Chapitre 1

Méthodologie

1.1 La base de données : de la donnée brute au nettoyage

Pour mener à bien cette étude, nous avons utilisé la base DVF+ (Demandes de Valeurs Foncières), une source administrative qui recense l'intégralité des transactions immobilières réalisées en France. Pour notre projet, nous nous sommes concentrés sur la région Occitanie sur une période de dix ans, allant de janvier 2014 à début 2024. Cette base est extrêmement riche puisqu'elle nous fournit non seulement le prix de vente (la valeur foncière), mais aussi la date de mutation, la localisation précise (code commune, département) et les caractéristiques physiques du bien (surface réelle bâtie, nombre de pièces, type de culture pour le terrain). Avec plus de 4 400 communes potentielles à traiter, cette masse de données constitue une base solide, mais elle nécessite un travail de préparation rigoureux pour devenir exploitable.

Pour renforcer la portée de notre étude, nous avons choisi d'élargir la période d'analyse en intégrant des données dès 2010. Cela a nécessité la fusion d'une seconde source : une base couvrant toute la France pour la période 2010-2013, dont nous avons extrait uniquement les transactions occitanes.

Cette fusion a nécessité un travail d'harmonisation technique important. Puisque les structures de colonnes différaient entre les deux périodes, nous avons dû renommer et standardiser les variables clés (comme la surface réelle bâtie ou le code type local) pour assurer la continuité des données. Par la suite, nous avons appliqué un filtrage géographique précis sur la première base afin de n'isoler que les transactions situées dans les départements de l'Occitanie. Cette stratégie nous a permis de constituer un échantillon unique, cohérent et homogène de 2010 à 2024.

Le premier enjeu a été le filtrage des données. Travailler sur des données administratives brutes comporte un risque majeur : la présence de valeurs aberrantes ou "outliers". Si l'on garde des ventes à 1 € (souvent des cessions familiales déguisées) ou, à l'inverse, des prix au m^2 délirants dépassant les 50 000 €, on risque de fausser totalement les moyennes et de rendre nos indices instables. Nous avons donc appliqué plusieurs filtres successifs : l'exclusion des surfaces nulles ou incohérentes, le retrait des transactions multi-lots qui brouillent le prix unitaire, et le plafonnement des prix au m^2 selon les standards du marché régional. Sans ce nettoyage, le modèle hédonique tenterait d'expliquer des erreurs de saisie au lieu de traduire la réalité économique du marché occitan.

Une fois la base nettoyée, nous avons opéré une segmentation stricte en créant deux

bases de données distinctes : l'une pour les maisons et l'autre pour les appartements. Cette étape est indispensable car ces deux types de biens répondent à des logiques de prix totalement différentes. Par exemple, la présence d'un grand terrain est un moteur de prix essentiel pour une maison, alors qu'elle est inexistante pour un appartement où l'on privilégiera l'étage ou la présence d'un ascenseur. Mélanger les deux dans un même calcul reviendrait à comparer des objets incomparables.

Après ces étapes de filtrage et de séparation, notre échantillon final reste extrêmement massif, ce qui garantit la fiabilité statistique de nos futurs indices. Il nous reste plus de 564 506 observations pour les maisons et 397 690 pour les appartements. Ce volume est largement suffisant pour couvrir l'ensemble du territoire occitan, des zones urbaines denses comme le centre de Toulouse jusqu'aux communes plus isolées, tout en conservant une précision mensuelle sur dix ans.

C'est ici que l'on rentre dans le « moteur » de notre étude. Une fois la base de données propre, tout l'enjeu est de transformer ces milliers de transactions en un indicateur qui a du sens.

1.2 Modèle Hédonique

Pour construire notre indice, nous utilisons ce que l'on appelle un modèle hédonique. L'idée de base est assez intuitive : on considère que le prix d'un logement n'est pas un chiffre global figé, mais la somme de plusieurs caractéristiques. Une maison à Toulouse coûte cher parce qu'elle est à Toulouse, parce qu'elle a une certaine surface, et parce qu'on l'achète à un instant T où le marché est haut. Mathématiquement, nous utilisons le logarithme du prix $\log(P_i)$ comme variable à expliquer. Ce choix est crucial car il permet de transformer des relations complexes en variations de pourcentages, ce qui est beaucoup plus simple à interpréter pour mesurer l'évolution du marché.

Le cœur de notre code consiste à créer des variables muettes, ou « dummies », pour chaque facteur d'influence. Nous avons d'abord généré les effets fixes temporels γ_t, qui marquent chaque mois de l'année. C'est la variable la plus importante de notre projet car c'est elle qui capte la « valeur du temps » pure, une fois que tout le reste a été nettoyé. Parallèlement, nous avons créé des effets fixes pour chaque commune μ_c et chaque département δ_d. C'est ce qui permet au modèle de comprendre qu'une maison de 100 m^2 n'a pas la même valeur selon qu'elle se situe dans l'hyper-centre de Montpellier ou dans une zone rurale isolée. Enfin, nous avons ajouté des interactions département-année $\theta_{d,a}$ pour capter des tendances locales très spécifiques, comme un département qui connaîtrait un boom soudain alors que ses voisins stagnent.

Le véritable défi technique est apparu lors du passage au calcul. Avec plus de 2 900 variables explicatives à croiser avec près de 600 000 lignes, l'ordinateur se retrouve face à une matrice gigantesque que la mémoire vive (RAM) ne peut pas supporter. Si l'on utilisait une méthode classique, le logiciel planterait instantanément. Pour contourner cet obstacle, nous avons mis en œuvre une stratégie d'Efficient Programming en utilisant des matrices creuses (Sparse Matrices). Au lieu de stocker une mer de zéros pour chaque transaction, l'ordinateur ne retient que les informations utiles. Couplé à l'algorithme LSQR, qui résout les équations de manière itérative sans essayer d'inverser toute la matrice d'un coup, nous avons pu obtenir nos coefficients avec une précision totale tout en préservant les ressources de la machine. Cette étape n'est pas qu'un détail technique : c'est elle qui nous permet

de traiter l'intégralité de l'Occitanie d'un seul bloc plutôt que de devoir découper notre analyse et perdre en cohérence globale.

1.3 Construction de l'indice de prix

Une fois que le modèle a fini de "calculer", nous obtenons des milliers de coefficients. Mais ces chiffres bruts ne sont pas encore un indice utilisable. La dernière étape de notre méthodologie consiste donc à transformer ces résultats en une courbe claire et comparable : l'indice de prix en base 100. C'est ici que l'on passe de l'économétrie pure à une analyse concrète du marché immobilier occitan. La construction de l'indice suit une démarche rigoureuse en plusieurs étapes.

La première étape est le calcul du prix net (P^{net}). Pour chaque transaction, nous ne voulons garder que la composante temporelle. Pour cela, nous prenons le prix observé et nous soustrayons l'influence de toutes les autres variables (surface, commune, département). Mathématiquement, cela revient à calculer le résidu du modèle auquel on ajoute la constante et l'effet temporel. C'est ce prix "nettoyé"qui nous permet de dire que nous travaillons à qualité constante : nous avons artificiellement supprimé les différences entre les biens pour ne voir que l'évolution du marché.

La deuxième étape est la gestion de la représentativité locale. Comme nous l'avons vu dans le cours, une commune qui n'a que 2 ou 3 ventes par an ne peut pas avoir un indice fiable ; le moindre prix extrême ferait bondir la courbe. Nous avons donc appliqué une règle de sélection stricte : seules les communes avec plus de 30 transactions sur la période ont un effet fixe propre. Pour les autres, nous utilisons une méthode de correction par la moyenne des résidus ($\bar{e}_c$). Cette astuce statistique permet de "recaler" les petites communes sur le bon niveau de prix sans créer de volatilité artificielle.

Cependant, même avec cette correction, certaines communes présentent des mois sans aucune transaction. Pour obtenir une courbe continue et éviter les "trous" dans nos graphiques, nous avons procédé à la prédiction des valeurs manquantes. En utilisant les coefficients estimés par le modèle (l'effet de la commune μ_c combiné à l'effet du mois γ_t), nous avons calculé un prix net théorique pour chaque période vide. Cette étape est fondamentale : elle nous permet de maintenir une série temporelle complète pour chaque territoire, assurant ainsi la cohérence de l'indice sur toute la décennie.

Vient ensuite l'étape de l'agrégation et du passage en base 100. Pour chaque mois et chaque commune, nous fusionnons les données observées et prédites pour calculer la médiane des prix nets. Nous privilégions la médiane à la moyenne car elle est beaucoup plus robuste : elle n'est pas influencée par une vente exceptionnelle qui pourrait fausser la tendance du mois. Nous avons choisi le mois de janvier 2014 comme point de référence (t_0). Concrètement, cela signifie que toutes les valeurs sont ramenées à une base de 100 au début de la période : si l'indice d'une ville affiche 120 en 2022, on comprend immédiatement que les prix ont grimpé de 20 % depuis 2014. La formule utilisée est :

$$Index_{c,t} = 100 \times \exp\left(\log P^{net}_{c,t} - \log P^{net}_{c,t_0}\right)$$

Ainsi, toutes les courbes partent du même point, ce qui rend la lecture des performances immédiate.

Enfin, la dernière étape est le lissage par moyenne mobile. Les données immobilières

mensuelles sont naturellement “bruitées”. Pour faire ressortir la tendance de fond et rendre les graphiques interprétables, nous appliquons une moyenne mobile sur 6 mois. Ce lissage est essentiel pour éliminer les micro-variations saisonnières et permettre une comparaison propre entre nos indices communaux et le benchmark départemental, qui sert de témoin pour valider la cohérence de nos résultats.

Chapitre 2

Résultats et discussions

2.1 Analyse et validation du modèle hédonique

Avant de procéder à l'agrégation des indices, il est impératif de valider la qualité du "moteur" de calcul : le modèle hédonique. Pour rappel, l'objectif est d'estimer l'équation structurelle suivante, telle que définie dans le cadre méthodologique du projet :

$$\log(P_{i,c,t}) = \alpha + x_i'\beta + \gamma_{t(i)} + \delta_{d(i)} + \mu_{c(i)} + \theta_{d(i),a(i)} + \epsilon_i$$

Cette étape permet de s'assurer que les coefficients extraits traduisent une réalité économique cohérente et que le modèle "ajuste" correctement les données observées.

Fiabilité statistique et qualité de l'ajustement

L'estimation a été réalisée par l'algorithme LSQR sur des matrices creuses, permettant de traiter simultanément 725 965 transactions pour les maisons et 596 000 pour les appartements. La validité du modèle est confirmée par le coefficient de détermination (R^2), qui mesure la part de variance du prix expliquée par nos variables. Nous obtenons des scores solides pour des données administratives massives :

$R^2 = 0,4924$ pour les appartements.
$R^2 = 0,4308$ pour les maisons.

Ces résultats indiquent que près de la moitié de la formation du prix en Occitanie est expliquée par les caractéristiques intrinsèques (surface, pièces) et la localisation géographique (commune, département). Le reste de la variance dépend de facteurs non recensés dans la base DVF+, comme l'état d'entretien ou l'exposition du bien.

2.2 Évolution des prix par type de bien (Maisons et Appartements)

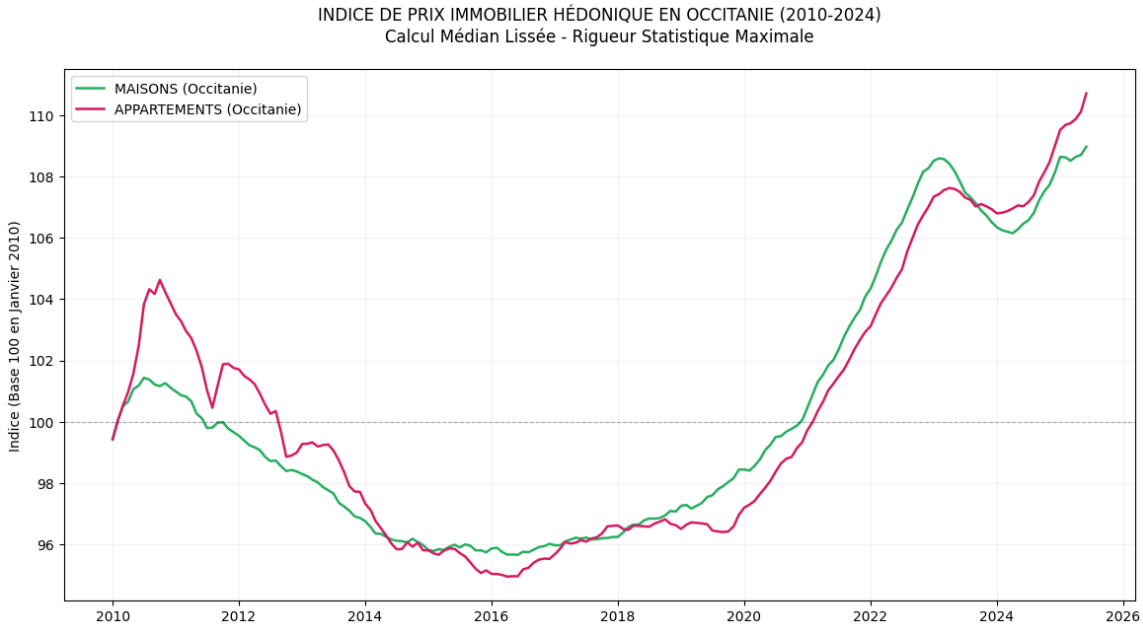

FIGURE 2.1 – Évolution des indices hédoniques des maisons et des appartements en Occitanie (base 100 en janvier 2010)

L'analyse de nos indices hédoniques permet de comparer l'évolution réelle de la valeur des maisons et des appartements en Occitanie depuis 2010. Le premier constat, visible sur la Figure 2.1, est une phase de baisse commune entre 2011 et 2016. Durant cette période, les prix ont diminué d'environ 4 % par rapport à leur niveau initial. On observe toutefois une différence de réaction : les appartements (courbe rose) ont connu une chute plus rapide et plus marquée dès 2012, alors que le prix des maisons (courbe verte) a suivi une baisse plus lente et régulière.

À partir de 2018, le marché entame une phase de reprise qui s'est accélérée brusquement après 2020 (Figure 2.1). On note alors une inversion des dynamiques : le segment des maisons individuelles affiche une croissance plus forte que celui des appartements entre 2021 et 2022. À caractéristiques et localisations constantes, la valeur d'une maison a progressé de près de 10 points en seulement deux ans. Au terme des quinze années d'analyse, l'indice des appartements termine avec une hausse globale de 11 %, contre environ 9 % pour les maisons.

Plusieurs facteurs permettent d'expliquer ces trajectoires distinctes.

La nature de l'achat et la sensibilité aux taux

Le marché des appartements est très concentré à Toulouse et Montpellier, où l'on trouve beaucoup d'investissements locatifs. Ces acheteurs sont très réactifs aux conditions de crédit et à la fiscalité : ils arrêtent d'acheter dès que la rentabilité baisse, ce qui explique la chute rapide après 2011. À l'inverse, l'achat d'une maison correspond souvent à une résidence principale pour un projet de vie familiale. Ce marché est plus stable car les propriétaires, attachés à leur logement, sont moins pressés de vendre en cas de baisse, ce

qui soutient les prix.

Le changement de priorités après 2020

Le décrochage positif des maisons après la crise sanitaire illustre une modification des besoins des ménages. Avec le développement du télétravail, la proximité immédiate du bureau est devenue moins cruciale que la présence d'une pièce supplémentaire ou d'un jardin. Ce transfert de la demande vers l'habitat individuel a permis aux maisons de rattraper en deux ans une grande partie du retard accumulé durant la décennie précédente.

2.3 Disparités géographiques et poids des métropoles

Au-delà de la tendance régionale, l'analyse des données par commune révèle que l'Occitanie est un territoire très contrasté. Le marché immobilier est fortement polarisé autour de ses deux métropoles, Toulouse et Montpellier, qui agissent comme les véritables moteurs de la région.

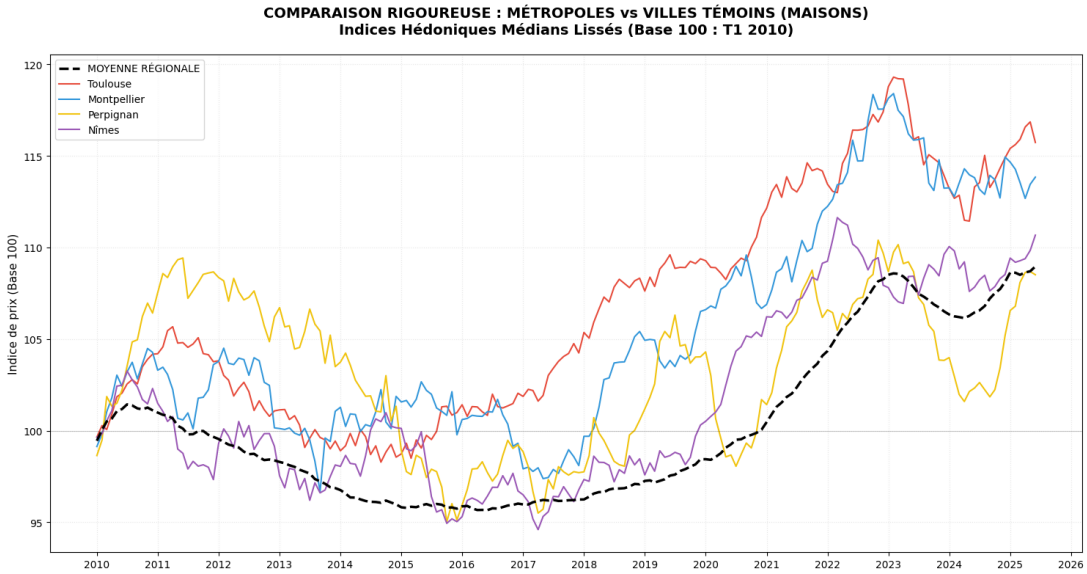

FIGURE 2.2 – Comparaison des indices de prix hédoniques — Métropoles vs Villes témoins (Maisons, 2010-2024)

La domination des métropoles régionales :

Le graphique comparatif des villes témoins (Figures 2.2 et 2.3) met en évidence une surperformance nette de Toulouse et Montpellier par rapport à la moyenne régionale (ligne noire en pointillés). Alors que la région affiche une hausse globale de 9 %, les deux métropoles ont atteint des sommets de croissance proches de +20 % au pic de 2023. Cette dynamique s'explique par la concentration massive des emplois (aéronautique à Toulouse, secteur numérique et médical à Montpellier) qui attire chaque année des milliers de nouveaux arrivants. À l'inverse, des villes comme Perpignan ou Nîmes montrent des trajectoires plus irrégulières (Figures 2.2 et 2.3) : leurs prix dépendent moins de l'emploi local et davantage des cycles de l'investissement locatif ou des résidences secondaires.

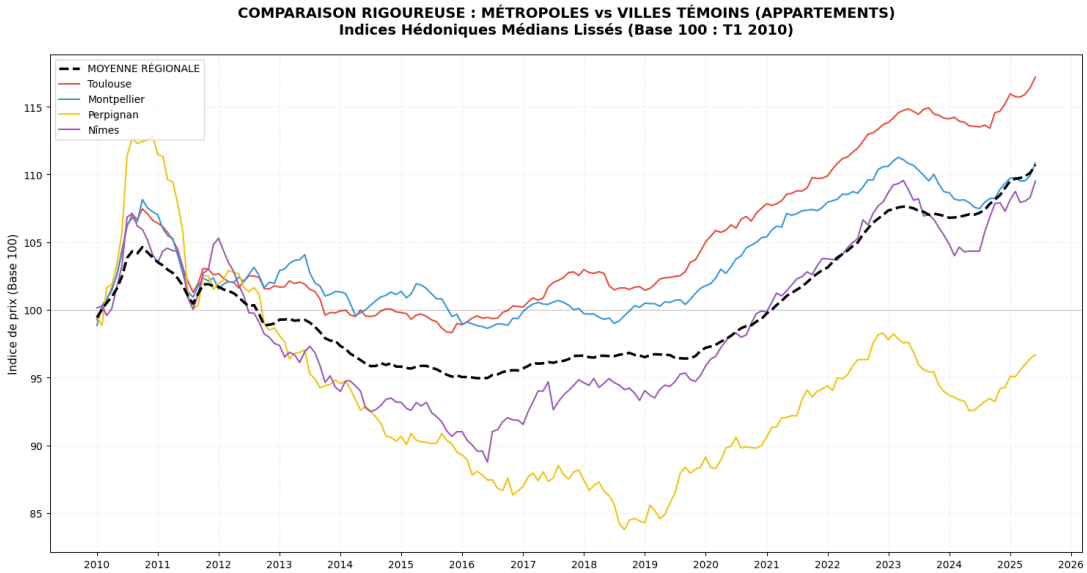

FIGURE 2.3 – Comparaison des indices de prix hédoniques — Métropoles vs Villes témoins (Appartements, 2010-2024)

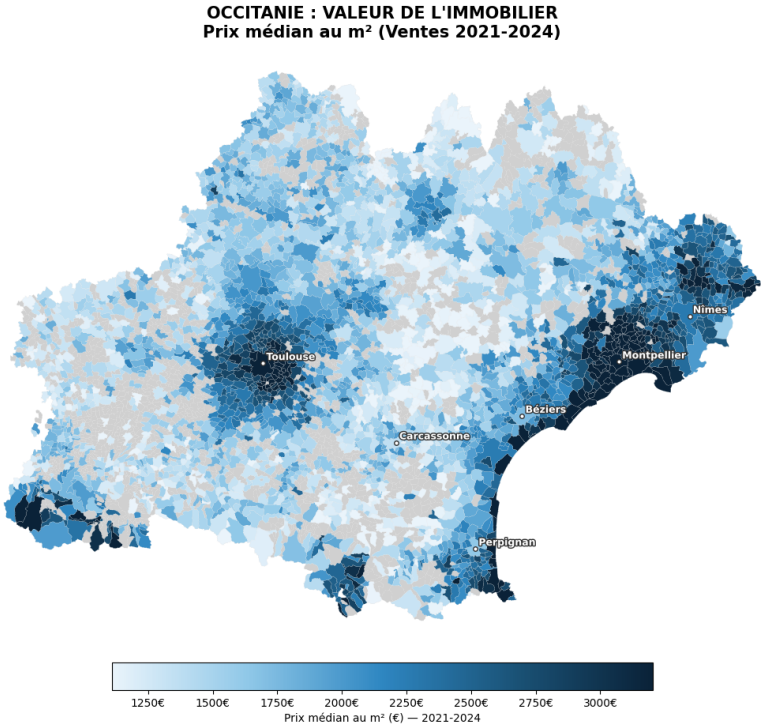

FIGURE 2.4 – Répartition géographique des prix immobiliers en Occitanie — Prix médian au m² par commune (2021-2024)

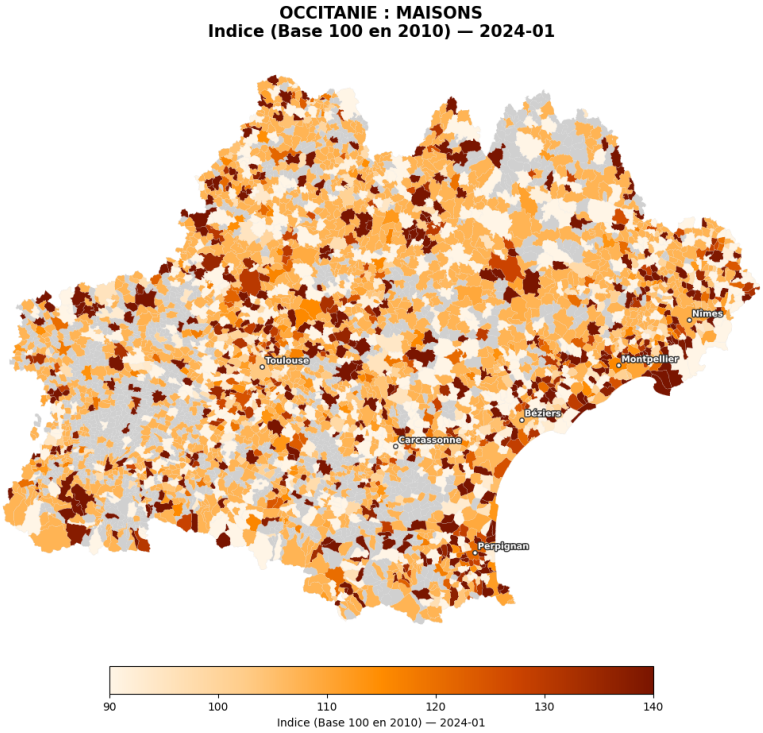

FIGURE 2.5 – Évolution de l'indice des prix des maisons (base 100 : 2010)

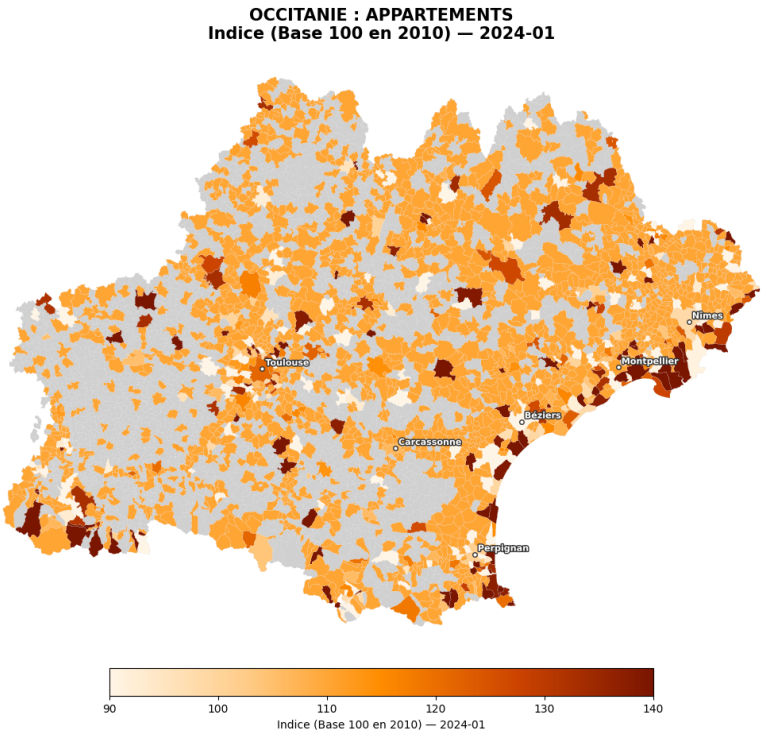

FIGURE 2.6 – Évolution de l'indice des prix des appartements (base 100 : 2010)

Une fracture territoriale entre centres urbains et zones rurales :

Nos trois cartes illustrent la polarisation du territoire occitan sous deux angles complémentaires : le niveau des prix en valeur absolue et leur évolution depuis 2010. Lues ensemble, elles permettent de comprendre les dynamiques spatiales qui structurent le marché immobilier régional.

La carte des prix au m² (Figure 2.6) confirme visuellement ce qui a été établi précédemment : les valeurs les plus élevées se concentrent dans les aires métropolitaines et le long du littoral méditerranéen. En s'éloignant de ces pôles, les prix chutent rapidement. L'attractivité des grandes villes rayonne sur leurs communes voisines, mais cette influence s'estompe dès que l'on entre dans l'arrière-pays rural comme le Gers, l'Ariège ou la Lozère.

Un effet de rattrapage dans les territoires intermédiaires :

Les cartes d'évolution de l'indice nuancent ce constat. Les communes affichant les hausses les plus fortes depuis 2010 ne sont pas toujours les plus chères en valeur absolue. On observe une forte progression dans des communes périurbaines de taille intermédiaire, autour de Carcassonne ou dans l'Hérault intérieur, où des ménages exclus des centres-villes se sont reportés, faisant monter les prix plus rapidement que dans les métropoles elles-mêmes.

Le rôle particulier du littoral méditerranéen :

Le littoral combine cherté structurelle et dynamisme récent, du fait de la rareté foncière et de la double pression entre résidents permanents et résidences secondaires. Ce marché obéit à des logiques propres, relativement indépendantes de la conjoncture économique générale.

Une divergence maisons / appartements :

Enfin, la comparaison des deux cartes d'indice révèle que les fortes hausses des maisons sont géographiquement plus dispersées, y compris en zone rurale, tandis que les appartements progressent de façon plus concentrée autour des pôles urbains. Ce contraste, cohérent avec les tendances temporelles analysées précédemment, confirme le transfert de demande vers l'habitat individuel dans des zones plus diffuses depuis 2020.

2.4 Analyse des cycles de marché

La dernière étape de notre analyse porte sur la dimension temporelle et les ruptures qui ont marqué la période 2010-2024. L'examen des indices lissés et de la heatmap permet d'identifier des cycles de marché très nets, souvent dictés par des événements économiques ou sanitaires.

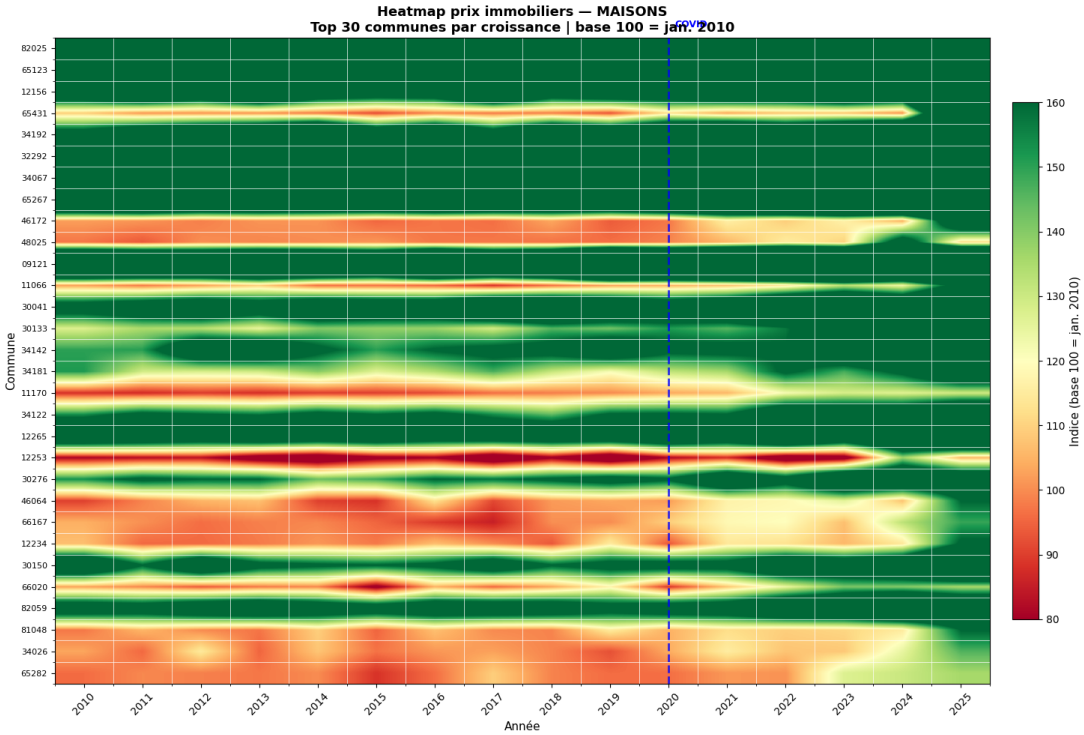

FIGURE 2.7 – Analyse temporelle par commune (Maisons) — Heatmap de la croissance des prix (Base 100 : janvier 2010)

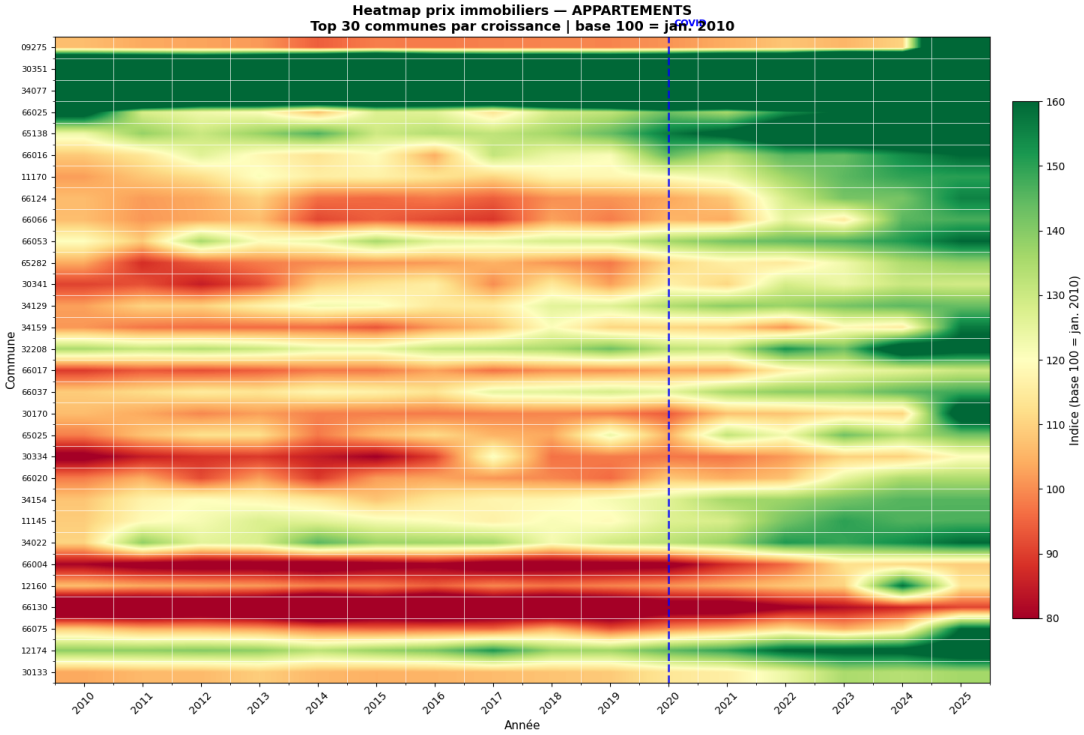

FIGURE 2.8 – Analyse temporelle par commune (Appartements) — Heatmap de la croissance des prix (Base 100 : janvier 2010)

La rupture de 2020 : l'effet de la crise sanitaire :

Le cycle le plus marquant commence avec la crise sanitaire. Avant 2020, le marché suivait une progression lente. La heatmap (Figures 2.7 et 2.8) montre un changement de couleur net après cette date : de nombreuses communes qui stagnaient depuis plusieurs années ont vu leurs prix augmenter rapidement. Ce mouvement a été global, touchant aussi bien les villes que les zones rurales. Cette période se traduit par une hausse de l'indice régional de près de 10 points en seulement deux ans, une accélération bien plus forte que sur toute la décennie précédente.

Le retournement de 2023 : l'impact des conditions de financement :

Cette phase de hausse s'interrompt au cours de l'année 2023. On observe sur nos graphiques (Figure 1) une inflexion des courbes, qui commencent à plafonner ou à baisser légèrement. Ce changement de tendance correspond à la remontée rapide des taux d'intérêt, qui a réduit la capacité d'emprunt des ménages. Ce nouveau contexte marque la fin d'un cycle de "crédit facile" et force le marché immobilier à une phase de stabilisation, visible à la fin de nos séries en 2024.

Plusieurs éléments clés permettent d'expliquer ces cycles :

Le lien avec les taux d'intérêt :

Le marché immobilier dépend directement du crédit. Entre 2018 et 2022, les taux historiquement bas ont permis aux acheteurs d'emprunter davantage, ce qui a fait monter les prix. Le coup d'arrêt de 2023 montre que les prix finissent toujours par s'ajuster à la réalité financière des acquéreurs : quand emprunter coûte trop cher, la demande baisse et les prix finissent par suivre.

L'évolution des priorités (télétravail) :

Le cycle post-2020 a été amplifié par de nouveaux modes de vie. Le besoin d'espace et la possibilité de s'éloigner des bureaux ont créé une pression très forte sur l'offre de maisons. Cette envie soudaine d'habitat individuel a provoqué une hausse rapide des prix avant que le marché ne retrouve un équilibre plus calme.

Conclusion

Ce projet a permis de transformer une masse de plus de 900 000 transactions administratives brutes en une lecture cohérente du marché immobilier occitan entre 2010 et 2024. L'utilisation du modèle hédonique s'est avérée essentielle pour dépasser la simple moyenne des prix et mesurer l'évolution de la "valeur pure" des biens à qualité constante, en neutralisant les effets de surface ou de localisation. Au terme de cette analyse, trois dynamiques majeures se dessinent : la domination structurelle des métropoles de Toulouse et Montpellier qui tirent la croissance régionale vers le haut, le basculement des préférences vers l'habitat individuel après la crise sanitaire de 2020, et enfin le coup d'arrêt brutal observé en 2023 sous l'effet de la remontée des taux d'intérêt. Ces résultats montrent que si l'Occitanie reste attractive, la fracture entre les centres urbains denses et les zones rurales isolées continue de se creuser.

Cependant, la manipulation de ces données réelles nous confronte à des limites structurelles qu'il convient de nuancer pour ne pas sur-interpréter les courbes obtenues. La principale zone d'ombre réside dans l'absence d'informations sur l'état intérieur et la performance énergétique des logements dans la base DVF+. Alors que le confort et l'isolation (DPE) pèsent aujourd'hui de manière décisive sur le prix de vente, notre modèle ne peut capter cette "valeur verte", ce qui peut biaiser l'analyse de certains biens anciens. De plus, l'immobilier est un marché caractérisé par une forte inertie : il existe souvent un décalage de plusieurs mois entre un choc économique, comme la hausse du coût du crédit, et l'ajustement effectif des prix par les vendeurs. Nos derniers points d'indice pour 2024 ne sont donc que le reflet d'un mouvement de stabilisation qui est encore en cours de consolidation.

Enfin, la fiabilité de nos indices dans les zones à très faible volume de transactions reste un défi statistique permanent. Malgré les corrections apportées pour limiter la volatilité dans les communes rurales, le prix médian y demeure plus sensible à quelques ventes atypiques que dans les grandes agglomérations. À l'avenir, l'intégration de variables environnementales ou de données sur la proximité des services permettrait d'affiner encore davantage ces indices.